

面向三种硬件场景的神经网络多核切图与协同调度研究

第一章 问题重述

1.1 问题背景

神经网络计算图由相互依赖的计算操作和中间张量构成。将计算图部署到多核处理器时，操作如何切分、分配到哪些核心以及各核心按什么顺序执行，会共同影响执行时间和数据搬运量。矩阵与向量操作的工作特征不同，核心间传输还会消耗同步和带宽资源；有限的片上存储则可能引发换入换出。因此，调度方案需要根据计算图结构和硬件执行规则联合确定。

本题设置了三个执行场景：问题一将子图作为独立任务，问题二允许同核子图合并执行，问题三在问题二基础上启用共享 FIFO 缓存。三个场景具有不同的任务边界、通信开销和数据复用方式，需要分别建立目标与约束。

1.2 问题重述

问题一：独立子图任务下的切图与调度。给定计算图、核心数及硬件配置，将操作划分为子图，为子图分配核心并确定各核心上的执行顺序。每个子图对应一个独立 Task。Task 间等待依赖前驱所在核心：题面规定核内等待为 100 cycles、跨核等待为 1000 cycles；同一核心上相邻 Task 的边界数据也按题目规则处理。要求在满足依赖、Task 顺序和存储规则的前提下缩短全图完成时间。

问题二：同核 Task 合并下的通信协同调度。在问题一的计算图及核心分配框架上，将同一核心上的子图合并为一个 Task。跨核依赖需要经过 COPY_OUT、同步和 COPY_IN，跨核同步延迟为 500 cycles。同核数据可在片上复用。模型需在核间并行收益、跨核通信、Pipe 负载均衡和片上存储压力之间进行权衡。

问题三：启用共享 FIFO L2 缓存的调度。沿用问题二的同核 Task 合并与跨核通信规则，增加共享只读 FIFO L2 缓存。L2 容量为 1 MiB、带宽为 250 B/cycle；DDR 为共享 60 B/cycle，Cache 初始为空。模型需考虑请求发射次序、未命中读取完成后的插入和 FIFO 淘汰对命中结果的影响，并比较 Cache 对 DDR 流量与总完成时间的作用。

三个场景共用的片上容量为 $L1=524,288$ B、 $UB=131,072$ B。容量约束和带宽约束分别描述数据驻留和搬运速率，应独立处理。

第二章 问题分析

2.1 问题一的分析

问题一中，一个子图就是一个 Task。切分粒度会影响 Task 数量、Task 等待和边界张量处理，也决定操作能否分散到多个核心并行执行。弱连通分量内部没有跨分量依赖，可作为初始装箱单元；但若一个连通分量占据大部分操作或计算周期，单纯按分量分配会限制并行度，需要进一步考察合法的拓扑切分。

对当前问题一冻结求解器，结构方法包括双 Pipe 分量装箱、依据图深度/汇合/共享关系切分、按就绪 Task 贪心分配核心及有界合并。求解过程使用固定策略，不在单个输入上调用官方评估器挑选候选。调度分析至少需要考虑每核矩阵和向量工作量、依赖关键路径、Task 激活、DDR 搬运与片上容量。总计算量均分不能反映不同 Pipe 的负载差异；各依赖等待也可能重叠，不能简单累加为实际完成时间。

2.2 问题二的分析

问题二将同核子图合并为一个 Task，核内数据复用更直接，但跨核依赖需承担 COPY 与同步代价。若为减少通信而把相关操作集中到一核，可能出现矩阵或向量 Pipe 过载；若将计算分散到更多核心，又可能增加跨核搬运并占用共享 DDR 带宽。

当前问题二模型以双 Pipe 负载、跨核关键路径、DDR 流量和静态张量存活压力构造候选排序代理，并从有限的分量装箱、深度带和数据感知切分方案中选择。静态内存压力不等同官方 Step 2 的准确 spill 量；正式 makespan、实际搬运及容量行为仍以冻结方案后的官方执行为准。开发阶段对风险系数进行全局标定，不能把在给定 100 图上取得的结果解释为分布外保证。

2.3 问题三的分析

问题三在问题二基础上引入 FIFO 缓存。张量是否命中，取决于读请求发生时张量是否已完成读取并插入缓存，以及此前插入的数据是否已将其淘汰。命中不刷新 FIFO 顺序，超过容量的张量不能驻留。因此，单独统计复用次数无法判断实际命中。

当前问题三冻结版本依据输入图构造有限种结构方案，并用自身的事件与驻留模型排序；每次推理不调用官方评估器或读取历史解。开发诊断使用过给定图集的官方反馈，故需将“单次推理不调用评估器”与“全局开发未使用评分标签”区分。缓存命中能减少 DDR 读取，但命中流量仍占用 L2 带宽。缓存收益应在同一冻结方案下配对比较，以避免把切图差异误认为缓存收益。

2.4 统一的多目标设计

令方案为 π ，问题编号为 $q \in \{1, 2, 3\}$ 。在结构合法且满足片上存储约束的方案集合内，分别考虑：

$$\begin{aligned}\min \mathbf{f}_1(\pi) &= (T_1(\pi), Q_1(\pi), I_{\text{imb},1}(\pi)), \\ \min \mathbf{f}_2(\pi) &= (T_2(\pi), Q_{\text{cross},2}(\pi), I_{\text{imb},2}(\pi)), \\ \min \mathbf{f}_3(\pi) &= (T_3(\pi), Q_{\text{DDR},3}(\pi), -Q_{\text{hit},3}(\pi), I_{\text{imb},3}(\pi)).\end{aligned}$$

其中， T_q 为全图完成时间， Q_q 表示场景相应的新增通信或 DDR 字节， $Q_{\text{hit},3}$ 为 FIFO 命中字节， $I_{\text{imb},q}$ 为核心/Pipe 工作量不均衡度。存储容量作为硬约束单独检查，不再作为目标重复惩罚；问题三的 1 MiB FIFO 容量由题设缓存插入与淘汰规则保证。真实时间、换入换出量和缓存命中以官方执行程序为准；搜索阶段若使用估计量，须明确标为代理值。

令 $x_{vk} \in \{0, 1\}$ 表示操作 v 是否分配到核心 k ， r_v 表示其合法拓扑执行序位。基本结构约束为：

$$\sum_{k=0}^{n-1} x_{vk} = 1 \quad (\forall v \in V), \quad r_u < r_v \quad (\forall (u, v) \in E).$$

此外还需保证每个子图唯一分核、每核子图序列合法，且原始依赖与同核顺序联合后无环。

对每个核心 k ，理想内存可行性约束为：

$$H_{k,\text{L1}}(\pi) \leq 524288, \quad H_{k,\text{UB}}(\pi) \leq 131072.$$

DDR/L2 带宽可导出完成时间下界：

$$T_q(\pi) \geq \max \left\{ \max_{k,p} W_{kp}(\pi), L_{\text{dep},q}(\pi), \frac{Q_{D,q}^{\min}(\pi)}{60}, \mathbf{1}_{q=3} \frac{Q_{L,q}^{\min}(\pi)}{250} \right\}.$$

该式给出资源和依赖下界，不是精确 makespan 的可加公式。多个资源可能并行工作，最终时间应由官方离散事件模拟决定。方案 π_a 支配 π_b ，是指所有待最小化指标均不劣且至少一项严格更优。透明的决策流程是先筛选结构和内存不可行方案，再保留 Pareto 非支配解，最后使用预先固定且仅依赖输入图与硬件参数的规则输出单一方案。

第三章 模型假设

1. **计算图假设**。输入操作与张量依赖构成有向无环图；操作周期、执行 Pipe、张量大小和存储位置按官方数据读取。

2. **分配唯一性假设**。每个操作被且仅被分配到一个子图；每个子图被且仅被分配到一个核心。

3. **执行顺序假设**。方案满足原始依赖，以及题目规定的 Task 依赖和核心内子图顺序。只施加题目实际要求的有向无环约束。

4. **资源容量假设**。L1 和 UB 是分别受限的片上资源，不能将两者容量合并后判断可行。

5. **共享带宽假设**。DDR 与问题三中的 L2 按题设作为共享带宽池；带宽下界不等同实际执行时长。

6. **FIFO 假设**。问题三缓存按题目 FIFO 查询、插入与淘汰规则工作；不假设题目未规定的预取或预热行为。

7. **描述统计假设**。第五章仅汇总官方 100 个原始输入图的结构和规模特征，不将评估器输出混入输入统计。

8. **近似量边界**。逻辑生命周期峰值、预测命中和资源时间下界用于分析或候选排序，不宣称它们等于官方执行器测得的峰值、命中或 makespan。

9. **评估器边界**。当前单次推理不调用官方评估器；开发标定可能使用评分反馈，二者在方法叙述和结果解释中分别说明。

第四章 符号说明

第五章 描述性统计

5.1 数据来源与预处理

统计对象为官方输入目录中的 100 个计算图。处理过程保留原始操作周期、张量字节数、图边和案例编号，并从原图计算操作数、DAG 边数、弱连通分量数、最大分量占比、矩阵/向量周期、关键路径、张量总字节及共享外部输入等特征。输入文件 SHA256 和 7 项基础 profile 均与项目清单逐图核对，100/100 匹配。

规模特征的原始值保留在 CSV 与统计 JSON 中；为了显示不同数量级，绘图时对长尾计数使用对数坐标，不对数据做截尾或 winsorize。比例变量保留在 $[0, 1]$ 。本章仅分析输入特征，不读取完成时间、加速比、spill 或 Cache 评估输出。

5.2 数据规模与计算特征

表 5-1 中每项依次给出最小值、第一四分位数、中位数、均值、第三四分位数和最大值。

表 5-1 100 个输入图的规模和计算特征

总计算周期的均值约为 318 万 cycles，中位数约为 51 万 cycles，说明少数大图显著拉高均值。 W/S 定义为总操作工作量与计算关键路径之比，仅表示图结构提供的并行空间，不是可实现的加速比。

符号	含义	单位/范围
$G = (V \cup \mathcal{T}, E)$	操作、张量和依赖边组成的计算图	—
$V, \mathcal{T}, E$	操作、张量、依赖边集合	—
d_v	操作 v 的计算周期	cycles
$p(v)$	操作 v 使用的 Pipe 类型	矩阵/向量等
b_t	张量 t 的大小	B
$\text{pos}(t)$	张量 t 的存储层级	L1/UB
n, k	核心数和核心索引	$k = 0, \dots, n - 1$
$\phi(v)$	操作到子图的映射	—
$\kappa(s)$	子图 s 到核心的映射	—
π_k	核心 k 上子图的执行序列	—
$\tau_q(v)$	场景 q 中操作对应的 Task	—
W_{kp}	核心 k 上 Pipe p 的总工作量	cycles
Q_q	场景 q 的相关搬运字节量	B
$H_{k,m}$	核心 k 在存储层级 m 的峰值占用	B
C_m	存储层级 m 的容量	B
B_D, B_L	DDR、L2 带宽	B/cycle
C_L	L2 容量	B
$T_q(\pi)$	官方执行器下方案 π 的完成时间	cycles
$L_{\text{dep},q}$	依赖与场景同步形成的关键路径下界	cycles
$I_{\text{imb},q}$	核心/Pipe 工作量不均衡度	无量纲
$Q_{\text{hit},3}$	问题三中的 L2 命中字节数	B

特征	min	Q1	中位数	均值	Q3	max
计算操作数	552	1,110.75	3,720.5	6,345.06	7,096	35,705
DAG 边数	400	1,266.25	4,017	7,406.41	8,269.75	38,493
总计算周期	23,052	162,732.75	509,952	3,179,741.84	1,848,864	61,275,840
关键路径周期	400	2,500.5	6,140	39,921.77	24,796.5	863,040
矩阵 Pipe 周期	0	63,177	256,920	2,728,477.23	1,345,339	58,915,232
向量 Pipe 周期	9,988	58,334	144,314.5	451,264.61	347,998.5	7,714,975
W/S 并行度代理	3.42	20.20	43.13	416.22	305.17	6,258.78




图 5-1 计算操作数、分量数、最大分量占比和向量 Pipe 占比的分布




图 5-2 总工作量与关键路径的关系

5.3 连通结构、张量与局部性特征

表 5-2 输入图的依赖结构和张量特征

特征	min	Q1	中位数	均值	Q3	max
弱连通分量数	1	17.5	39.5	146.97	107.25	2,666
最大分量节点占比	0.0004	0.0156	0.1220	0.3293	0.7288	1.0000
张量总数	816	1,593.25	4,590.5	7,477.86	8,004	40,287
张量总字节	325,708	3,921,341	9,366,784	29,375,957.16	24,141,591	360,593,104
外部输入张量数	12	130	254	486.68	556.5	4,362
外部输入字节	35,622	435,535	1,063,082	2,083,082.98	2,428,224	13,400,064
输出张量数	1	19.5	62	159.44	126.5	2,666
输出张量字节	2	271.5	16,689	324,217.56	160,768	4,094,976

100 个案例中有 16 个仅含一个弱连通分量，84 个含多个分量，且这 84 个案例均不少于 5 个分量。最大分量占比的中位数为 12.2%，上四分位数约为 72.9%，表明案例间既有分散的小分量，也有单一大分量占主导的图结构，单一分配策略难以覆盖全部情况。

97 个案例至少有一个共享外部输入张量。共享输入可能形成跨核复用机会，也可能因消费者被分配到多个核心而扩大通信。张量总字节均值明显高于中位数，反映不同案例的数据规模差异较大；后续通信和内存分析需同时考察字节数与消费者分布。




图 5-3 弱连通分量数量及最大分量占比




图 5-4 矩阵和向量 Pipe 构成及共享输入




图 5-5 图规模与计算特征的 Spearman 相关系数




图 5-6 按分量结构分组的关键特征中位数与四分位范围

5.4 变量相关性和结构分组

相关性图用于观察输入特征间的单调关联，不作因果解释。结构分组图以中位数和四分位范围描述组内差异。分量较多不必然意味着更高的并行收益；仍需结合各分量的矩阵/向量工作量、依赖深度和张量边界判断。

5.5 图结构代理候选及解释范围




图 5-7 图结构候选的代理目标 Pareto 对比

图 5-7 展示少量结构基线在资源下界、估计通信、逻辑存储超额和 FIFO 代理指标上的权衡。该图不使用官方评估器，不代表真实 makespan 排名、存储可行性证书或 100 个案例的算法性能结果。




图 5-8 三种执行场景的机制差异

参考文献

- [1] 《通用神经网络处理器下的多核切图与协同调度优化模型与算法》，2026 年 A 题第二篇论文，29 页，第 2 章、第 4—6 章及附录 A—C。
- [2] 2026 年 A 题题目说明及官方输入图、硬件执行配置。具体 Task、COPY、同步、容量和带宽语义以相应版本题面与官方执行程序为准。